Rúbrica breve: EDA y calidad de datos

Proyecto temático en notebook

Puntaje total: 4 puntos

No basta con encontrar un dataset. Deben explicar qué quieren conocer, para qué serviría conocerlo y si la calidad de los datos permite confiar en el análisis.

Pregunta que motiva el trabajo

Cada equipo debe formular una pregunta que dé sentido al análisis:

¿Qué aspecto de [tema elegido] queremos describir y cómo podría esa información ayudar a tomar una decisión, mejorar un proceso o generar valor económico o social?

La pregunta puede orientarse a **describir una situación**, **mejorar una decisión o proceso**, o **detectar una oportunidad de ahorro, ingreso o impacto social**. En esta entrega no es necesario responderla completamente: debe quedar claro por qué vale la pena estudiar los datos.

Rúbrica de evaluación

Criterio	1 punto	0.5 puntos	0 puntos
1. Tema, propósito y pregunta	Presenta el tema, una pregunta clara y explica si busca describir, mejorar una decisión o generar valor.	El tema está definido, pero la pregunta es general o no explica para qué servirá.	No existe una pregunta que oriente el trabajo.
2. Fuente y comprensión del dataset	Identifica fuente, periodo, tamaño, archivos, unidad de análisis y qué representa una fila. La carga es reproducible.	Presenta el dataset, pero falta información importante o la ruta depende de una computadora específica.	No identifica correctamente la fuente o el dataset no puede cargarse.
3. Descripción y diccionario	Incluye un diccionario de campos principales y usa `head()`, `shape`, `info()` y `describe()` con interpretación breve.	Muestra comandos de exploración o un diccionario incompleto, pero casi no interpreta los resultados.	Solo carga los datos o muestra resultados sin explicar las columnas.
4. Calidad y diagnóstico	Evalúa reglas aplicables de completitud, unicidad, validez y consistencia; cuantifica problemas y explica su impacto.	Revisa nulos y duplicados, pero no define reglas del dominio o no explica el impacto.	No evalúa la calidad o elimina datos sin justificación.

Alcance de esta entrega. El trabajo termina en el diagnóstico de calidad. No se exige todavía correlación, modelado predictivo, dashboard ni afirmaciones causales.

Contenido mínimo del notebook

1. Nombre del proyecto, tema elegido e integrantes.
2. Pregunta motivadora y utilidad esperada.
3. Fuente, periodo y condiciones de uso de los datos.
4. Unidad de análisis: explicación precisa de lo que representa una fila.
5. Carga reproducible y evidencia básica: `head()`, `shape` e `info()`.
6. Perfil descriptivo con `describe()` e interpretación de los resultados principales.
7. Diccionario de las columnas relevantes para la pregunta.
8. Evaluación de calidad con reglas justificadas.
9. Diagnóstico final con dos o tres problemas, su impacto y una acción sugerida.

Plantilla mínima del diccionario de datos

Columna	Descripción	Tipo o escala	Unidad o dominio	Importancia
`fecha_venta`	Fecha de la operación	Temporal	Fecha válida	Permite comparar periodos
`producto`	Producto vendido	Categórica	Catálogo de productos	Permite comparar categorías
`cantidad`	Unidades vendidas	Numérica discreta	Mayor o igual a cero	Mide el volumen
`importe`	Valor de la venta	Numérica continua	Soles, no negativo	Mide el valor económico

Plantilla mínima de calidad

Dimensión	Regla	Resultado	Impacto sobre el trabajo
Completitud	`producto` no debe ser nulo	98.5 %	Los nulos impiden analizar ventas por producto
Unicidad	`id_venta` debe ser único	99.8 %	Los duplicados inflan las ventas
Validez	`cantidad >= 0`	99.9 %	Los negativos distorsionan los totales
Consistencia	`importe = cantidad * precio`	97.4 %	Las diferencias afectan el cálculo de ingresos

Cierre esperado del equipo

El notebook debe terminar con un diagnóstico breve que responda:

1. ¿Qué problema de calidad encontraron?

2. ¿Cuántos registros o qué porcentaje afecta?

3. ¿Cómo puede alterar la descripción o la decisión planteada?

4. ¿Qué acción proponen y quién debería atenderla?

Primero comprendemos el problema y los datos. Después evaluamos si la evidencia tiene la calidad necesaria para sostener el análisis.
