Variables derivadas de la capa Silver: por qué se crearon y para qué sirven

Proyecto «¿Cuándo un accidente se convierte en colapso del tráfico?» · Big Data UNAJ 2026-2 · Basado en el diccionario de la celda 8.1 del notebook 02_cleaning/03_silver_accidentes_eeuu.ipynb y en los resultados del notebook 03_analysis/04_analisis_accidentes_eeuu.ipynb

¿Qué es una variable derivada?

Es una columna que **no viene en el CSV original (Bronze)**: se calcula en Silver a partir de otras columnas. Se crean por tres motivos: (1) **responder la pregunta** de forma simple (por ejemplo, convertir la severidad 1–4 en Sí/No), (2) **controlar la calidad** sin borrar registros (marcas o flags) y (3) **agrupar** valores con muchas categorías en pocas, fáciles de comparar y explicar.

Resumen

Columna derivada	Dimensión de calidad	Nivel de análisis donde se usa	Importancia
`grupo_severidad`	Consistencia	Diagnóstico (control de fuente)	Imprescindible
`alto_impacto`	—	Todos (variable objetivo)	Imprescindible
`duracion_min`	Consistencia	Ninguno (solo calidad)	Control
`flag_duracion_irreal`	Consistencia	Ninguno (marca)	Control
`anio / mes / hora`	—	Descriptivo, diagnóstico, predictivo	Alta
`anio_completo`	Oportunidad	Diagnóstico (comparar años)	Control
`franja_horaria`	—	Diagnóstico, predictivo, prescriptivo	Alta
`dia_semana / tipo_dia`	—	Descriptivo, diagnóstico, predictivo	Alta
`clima_confiable`	Exactitud	Diagnóstico (filtro de clima)	Control
`clima_grupo`	—	Descriptivo, diagnóstico	Alta
`visibilidad_grupo`	—	Diagnóstico	Media (resultado no concluyente)

Detalle de cada variable

`grupo_severidad`	**Consistencia · Diagnóstico**
Cómo se calcula	`Source2` → «A: Source2 2016-2022»; `Source1` con año ≥ 2021 → «B: Source1 2021-2023»; el resto → «Sin comparar».
Por qué se creó	La severidad **no se mide igual**: entre fuentes (avance: 8 % de alto impacto en Source1 frente a 34 % en Source2) y tampoco **dentro de Source1 con los años** (~33 % en 2016–2018 → menos de 3 % desde 2021, y deja de usar el nivel 3). Mezclar esos registros daría comparaciones falsas.
Importancia en el análisis	Es la variable **más importante del análisis**: toda comparación de severidad se hace dentro de A o de B y se resume con el **índice** (% del subgrupo ÷ % promedio de su grupo). Permite la regla de solidez: un patrón es «sólido» solo si aparece en A **y** en B. Sin ella se caería en la trampa de la celda 4.1 (el alto impacto parece caer de 35,8 % a 6,8 %).
Dato / cuidado	A = 231 374 accidentes (33,90 % alto impacto) · B = 199 249 (2,59 %) · Sin comparar = 106 667 (19,85 %, solo se usan para contar).

alto_impacto	Variable objetivo · Todos los niveles
Cómo se calcula	`Severity >= 3` → True / False.
Por qué se creó	La pregunta define «colapso del tráfico» como severidad 3 o 4. Pasar la escala 1–4 a Sí/No hace el cálculo simple: el promedio de `alto_impacto` es directamente el **% de accidentes de alto impacto**.
Importancia en el análisis	Es lo que se mide en todo el notebook 04: % por hora, franja, clima, vía y estado; índice; tabla predictiva (nivel 3) y cantidad de casos para las recomendaciones (nivel 4).
Dato / cuidado	Mide el impacto en el **tráfico**, no la gravedad de las lesiones.

duracion_min	Consistencia · Solo control de calidad
Cómo se calcula	`(End_Time - Start_Time)` en minutos.
Por qué se creó	Se necesita para comprobar que ningún accidente termina antes de empezar (regla de consistencia) y para detectar duraciones irreales.
Importancia en el análisis	**No se analiza**: depende de la fuente (mediana ~106 min en Source1 frente a ~45 min en Source2), así que compararla sería medir la forma de registrar y no el accidente. Queda en Silver por trazabilidad.
Dato / cuidado	0 accidentes con duración ≤ 0.

flag_duracion_irreal	Consistencia · Marca (no elimina)
Cómo se calcula	`duracion_min > 24 * 60` → True si dura más de 24 horas.
Por qué se creó	2 474 registros (0,46 % de la muestra) duran más de un día, algo que no corresponde a un accidente común. En vez de borrarlos se **marcan**, siguiendo la regla de la capa: no se elimina nada sin necesidad.
Importancia en el análisis	Deja evidencia del problema para el reporte de calidad. No cambia los resultados porque la duración no se usa en el análisis.
Dato / cuidado	0,45 % de Silver tiene la marca en True.

anio / mes / hora	Tiempo · Descriptivo, diagnóstico y predictivo
Cómo se calcula	Partes de `Start_Time`: `.dt.year`, `.dt.month`, `.dt.hour`.
Por qué se creó	`Start_Time` es una fecha completa; para agrupar («¿a qué hora?», «¿en qué año?») se necesitan sus partes por separado.
Importancia en el análisis	`hora`: gráfico de volumen por hora y el índice por hora (de 20 h a 3 h el alto impacto supera el promedio en ambos grupos). `anio`: define el grupo B (año ≥ 2021), separa los años de referencia y de verificación del nivel predictivo y permite ver la trampa de mezclar fuentes. `mes`: queda disponible en Silver; no se usó en las comparaciones.
Dato / cuidado	La hora es **local** del lugar del accidente: «las 8 a. m.» significa lo mismo en cualquier estado.

anio_completo	Oportunidad · Marca (no elimina)
Cómo se calcula	`anio.between(2017, 2022)` → True si el año tiene 12 meses de datos.
Por qué se creó	2016 empieza en febrero y 2023 solo tiene enero a marzo. Compararlos con años completos haría parecer que «hubo menos accidentes».
Importancia en el análisis	Las comparaciones entre años (celda 4.1) usan solo años completos. Es la dimensión de **oportunidad** aplicada al análisis.
Dato / cuidado	91,46 % de Silver está en años completos.

`franja_horaria`	**Tiempo · Diagnóstico, predictivo y prescriptivo**
Cómo se calcula	Función simple: 06–10 Punta mañana · 10–15 Mediodía · 15–19 Punta tarde · 19–22 Noche · 22–06 Madrugada.
Por qué se creó	Son las **franjas que definieron los autores del dataset** (Moosavi et al., 2019): se usa un criterio externo y no uno inventado. Además, 24 horas son muchas categorías; con 5 franjas cada grupo tiene suficientes casos (sobre todo en B, que tiene pocos accidentes de alto impacto).
Importancia en el análisis	Base de la matriz de solidez (la noche 19–22 h es sólida: índice 1,23 en A y 1,38 en B), del mapa de calor franja × día, de la tabla predictiva (franja × tipo de día) y de la comparación cantidad vs proporción (15–19 h tiene más casos por hora en ambos grupos).
Dato / cuidado	Una franja puede esconder parte del patrón: 22–06 sale «no concluyente» porque en A incluye las 4–5 h, que están bajo el promedio.

`dia_semana / tipo_dia`	**Tiempo · Descriptivo, diagnóstico y predictivo**
Cómo se calcula	`.dt.day_of_week` traducido a Lunes…Domingo; `tipo_dia` = «Fin de semana» si es sábado o domingo, si no «Laborable».
Por qué se creó	pandas devuelve el día como número o en inglés; se traduce para que el notebook se lea en español. `tipo_dia` resume la diferencia clave: los laborables tienen dos picos (7 h y 16 h) y el fin de semana uno solo (14 h).
Importancia en el análisis	`dia_semana` se usa en el mapa de calor franja × día. `tipo_dia` se usa en el gráfico de volumen, en la matriz de solidez (fin de semana: 1,69 en A y 1,08 en B → no concluyente) y en las 10 celdas de la tabla predictiva.
Dato / cuidado	Cada día laborable tiene 15,7–17,6 % de los accidentes; el sábado 8,6 % y el domingo 7,2 %.

`clima_confiable`	**Exactitud (plausibilidad) · Filtro**
Cómo se calcula	|`Weather_Timestamp - Start_Time`| ≤ 1 hora → True. Sin hora del clima → False.
Por qué se creó	Según el paper, el clima se toma de la estación de aeropuerto más cercana. Si además se midió lejos en el tiempo, no describe el momento del accidente.
Importancia en el análisis	El análisis de clima y visibilidad usa **solo** los registros con True. Los demás siguen sirviendo para hora, lugar y vía.
Dato / cuidado	97,23 % True. Solo garantiza la cercanía en el tiempo, no en el lugar: el clima sigue siendo una aproximación.

`clima_grupo`	**Clima · Descriptivo y diagnóstico (sub-pregunta 3)**
Cómo se calcula	Función `agrupar_clima`: busca palabras (thunder, snow, rain, fog, cloud, fair…) y asigna 7 grupos: Despejado, Nublado, Lluvia, Tormenta, Nieve o hielo, Niebla o humo, Otro.
Por qué se creó	`Weather_Condition` tiene más de 100 textos distintos que son variantes de lo mismo («Rain», «Light Rain», «Heavy Rain»). Con tantas categorías, muchas tendrían pocos casos y porcentajes inestables. El orden importa: «Light Rain with Thunder» es tormenta.
Importancia en el análisis	Responde la sub-pregunta 3: nieve o hielo es sólido con más alto impacto (1,31 y 1,42); niebla o humo, sólido con menos (0,86 y 0,71); lluvia no concluyente y tormenta contradictoria. «Otro» (250 casos) no se interpreta por muestra insuficiente.
Dato / cuidado	Reemplaza a la precipitación, que se excluyó por tener 28,58 % de nulos.

visibilidad_grupo	Clima · Diagnóstico (sub-pregunta 3)
Cómo se calcula	`pd.cut` en tres rangos: Muy reducida (< 1 mi) · Reducida (1–5 mi) · Normal (≥ 5 mi).
Por qué se creó	El sensor suele reportar como máximo 10 millas y la mayoría de valores es exactamente 10; como número continuo distingue poco. Los rangos separan los casos que importan: visibilidad reducida.
Importancia en el análisis	Ningún rango mostró un patrón común en A y B (todos «no concluyentes»): con estos datos, la visibilidad no acompaña al alto impacto. Que un resultado sea negativo también es información útil.
Dato / cuidado	481 550 en Normal, 35 189 en Reducida, 8 184 en Muy reducida y 12 367 sin dato.

Idea para la exposición

Las derivadas no agregan información nueva: **reorganizan** la que ya existe para que la pregunta se pueda responder con cuidado. Las más importantes son **alto_impacto** (qué medimos) y **grupo_severidad** (con qué comparamos); las marcas (**flag_duracion_irreal**, **anio_completo**, **clima_confiable**) permiten aplicar las dimensiones de calidad sin eliminar registros, y las agrupaciones (**franja_horaria**, **tipo_dia**, **clima_grupo**, **visibilidad_grupo**) hacen que cada comparación tenga suficientes casos para interpretarse.